

谱梯度更新的激活扰动几何： 局部理论与更新谱塑形实验证据

TBD

2026 年 6 月 12 日

摘要

谱梯度方法 (spectral gradient methods) 通过重塑矩阵更新的奇异值来改变优化动态。典型例子是极分解更新 $G = U\Sigma V^\top \mapsto UV^\top$ ，它保留梯度奇异向量，但将非零奇异值拉平。已有理论通常从逐层角度解释这类方法：当某个参数块的梯度核秩 (nuclear rank) 大于输入激活的稳定秩 (stable rank) 时，谱更新可能优于欧几里得梯度步。本文将这个观点整理为一个更一般的激活扰动几何框架。

我们首先证明：在一阶线性化目标下，梯度形状的更新是 Frobenius 范数预算下的最优方向，而极分解/谱更新是 operator 范数预算下的最优方向。这解释了为什么高秩更新并不天然带来更大损失下降。其次，我们把参数更新对隐藏激活的影响写成 $\Delta W A$ ，并指出谱更新提供的是 per-sample/operator-norm 意义下的扰动控制，但它可能增加 batch-level activation spreading。进一步地，若该层扰动通过下游 Jacobian B 传播到模型输出，则真正相关的量不是 $\text{srnk}(A)$ ，而是

$$\text{ssrnk}(B, A) = \frac{\sum_i \sigma_i(B)^2 \sigma_i(A)^2}{\sigma_1(B)^2 \sigma_1(A)^2},$$

这是映射 $D \mapsto BDA$ 在谱范数与 Frobenius 范数几何下的精确敏感度比。

实验部分目前采用 E11 控制实验作为局部机制证据：Muon-like 极分解更新稳定地产生更平、更高秩的 update spectrum；one-step 损失下降与梯度-更新内积高度相关；flat/polar 谱分配在 operator-norm 预算下胜出，但在 Frobenius 预算下失败；direct activation perturbation diagnostics 显示 Muon 在 matched update size 下可降低 operator/per-sample worst-case perturbation，但不统一降低 batch-Frobenius movement；神经网络 sanity checks 进一步说明高秩更新不自动意味着更好的一阶进展。尚未进行的 downstream Jacobian 与长尾小 batch 实验在本文中保留为待完成实验。

目录

1 引言	4
2 相关工作	5
3 问题设定与记号	5

目录	2
4 局部一阶谱几何	6
4.1 SpecGrad 家族	6
4.2 Frobenius 与 operator-norm 约束下的一阶最优性	7
5 激活扰动几何	7
5.1 Polar 更新的 operator-norm 控制	8
5.2 层级谱更新优势条件	8
6 下游敏感度与 Sandwiched Stable Rank	9
6.1 精确敏感度公式	9
6.2 Sandwiched stable rank	10
7 已有 E11 实验证据	10
7.1 更新谱塑形	11
7.2 一阶损失下降校准	11
7.3 范数几何边界	11
7.4 神经网络负控	11
7.5 预测边界尚未完成	12
8 实验计划与待完成实验	12
8.1 实验一: Activation perturbation diagnostics	12
8.2 实验二: Activation stable rank 与层级条件	13
8.3 实验三: Downstream-aware activation perturbation	13
8.4 实验四: 长尾小 batch 激活实验	14
8.5 实验五: 现代架构激活扰动 benchmark	14
9 讨论	14
10 结论	15
A 核心证明细节	16
A.1 谱范数球与核范数对偶	16
A.2 Frobenius 球与 Frobenius 范数对偶	16
A.3 Sandwiched sensitivity 的 Frobenius 情况	16
A.4 Sandwiched sensitivity 的 operator-norm 情况	16
B 建议实验指标与记录协议	17
B.1 更新谱指标	17
B.2 激活扰动指标	17
B.3 一阶进展指标	17
B.4 下游扰动指标	17

目 录	3
C 安全表述与需避免表述	18
C.1 可以安全使用的表述	18
C.2 应避免的表述	18

1 引言

深度网络中大量参数天然为矩阵：全连接层、MLP 投影、嵌入矩阵、卷积核的矩阵化表示、以及 Transformer 中的投影矩阵。标准一阶优化方法通常在欧几里得几何或坐标几何中更新这些矩阵。谱梯度方法则不同：它们直接作用于矩阵梯度的奇异值结构。

设某个矩阵参数块的梯度为

$$G = U\Sigma V^\top.$$

一般谱梯度更新可以写成

$$D_f(G) = Uf(\Sigma)V^\top,$$

其中 f 对奇异值进行重标定。最典型的极分解更新为

$$D_{\text{polar}}(G) = UV^\top.$$

它保留梯度奇异向量，但将非零奇异值全部设置为同一尺度。

近期工作已经从不同角度解释了这种更新。Davis 和 Drusvyatskiy 提出，当梯度的 squared nuclear-to-Frobenius ratio 大于输入激活稳定秩时，谱更新的一步下降界可能优于欧几里得梯度步 [1]。Chen、Li 和 Liu 则将 Muon 放入 Lion- $\mathcal{K}$ 框架，指出 Muon 对应核范数选择，并与谱范数约束优化相关 [2]。这些工作表明，谱更新不是单纯的数值技巧，而是对应一种不同的矩阵几何。

本文从另一个角度组织这一现象：激活扰动几何。给定某层输入激活矩阵

$$A_{\ell-1} = [h_{\ell-1}(x_1), \dots, h_{\ell-1}(x_B)],$$

该层 pre-activation 为

$$Z_\ell = W_\ell A_{\ell-1}.$$

若参数更新为

$$W_\ell^+ = W_\ell - D_\ell,$$

则直接 pre-activation 扰动为

$$\Delta Z_{\ell, \text{direct}} = -D_\ell A_{\ell-1}.$$

因此，讨论谱更新是否稳定或有效，不能只看 D_ℓ 的 rank 或 stable rank，而必须看

$$\|D_\ell A_{\ell-1}\|$$

以及该扰动通过后续网络传播后的函数影响

$$\|B_\ell D_\ell A_{\ell-1}\|.$$

本文的中心观点是：

谱梯度更新是 operator-norm 几何下自然的一阶方向，但其优化收益取决于激活与下游 Jacobian 的几何。

换言之，高秩/平谱更新只是机制事实；它是否带来损失下降或激活稳定，需要由 gradient alignment、activation stable rank、downstream sensitivity 共同决定。

2 相关工作

谱梯度更新与 Muon. 谱梯度方法将矩阵梯度的奇异值替换为某种变换后的谱。极分解更新 $G = U\Sigma V^\top \mapsto UV^\top$ 是 operator-norm 约束下一阶最速下降方向。Muon 可以视为这种谱更新思想的实际优化器实现或近似实现。Chen et al. [2] 将 Muon 解释为 Lion- $\mathcal{K}$ 框架中核范数对应的情形，并分析其与谱范数约束优化之间的联系。

层级 nuclear-rank vs stable-rank 条件. Davis and Drusvyatskiy [1] 提出，谱更新的优势可由逐层条件解释：对于梯度矩阵 G_ℓ 和输入激活矩阵 $A_{\ell-1}$ ，当

$$\frac{\|G_\ell\|_*^2}{\|G_\ell\|_F^2} > \frac{\|A_{\ell-1}\|_F^2}{\|A_{\ell-1}\|_{\text{op}}^2}$$

时，谱更新相对于欧几里得更新具有更好的 one-step 保证下降。本文将这个条件解释为 $B = I$ 的特殊情况，并引入下游敏感度 B 后的 sandwiched stable rank。

Stable rank normalization. 稳定秩也出现在泛化与 Lipschitz 控制中。Sanyal et al. [3] 提出 Stable Rank Normalization，通过控制线性层稳定秩和经验 Lipschitz 行为来改善泛化。本文的 stable rank 用法不同：它不是直接作为正则项，而是作为局部扰动几何中的敏感度比。

E11 实验套件定位. 本文使用的已有实验来自 E11 condition geometry 分支。该实验套件的问题设定是：Muon 是否作为 geometry-shaping optimizer 改变更新矩阵谱几何，以及这种几何是否解释 one-step 或短程优化进展。其当前 thesis 是：Muon 会产生更平、更高秩的 update spectrum，但是否有利取决于任务、层、范数约束、horizon 和调参。该实验套件在本文中作为局部谱几何机制证据，而非完整优化器性能证据。

3 问题设定与记号

设模型参数由矩阵块组成：

$$\theta = (W_1, \dots, W_L), \quad W_\ell \in \mathbb{R}^{m_\ell \times n_\ell}.$$

对一个 batch，模型输出为

$$F(\theta) \in \mathbb{R}^{c \times B},$$

损失为

$$\mathcal{L}(\theta) = \phi(F(\theta)).$$

令

$$G_\ell = \nabla_{W_\ell} \mathcal{L}(\theta)$$

为第 ℓ 个矩阵块的梯度。

若某层输入 activation matrix 为

$$A_{\ell-1} = [h_{\ell-1}(x_1), \dots, h_{\ell-1}(x_B)] \in \mathbb{R}^{n_\ell \times B},$$

则该层 pre-activation 为

$$Z_\ell = W_\ell A_{\ell-1}.$$

设正下降更新为

$$D_\ell = W_\ell - W_\ell^+.$$

那么固定输入激活时的直接 pre-activation 变化为

$$\Delta Z_{\ell, \text{direct}} = -D_\ell A_{\ell-1}.$$

如果激活函数 σ 是 L_σ -Lipschitz, 则

$$\|\Delta H_\ell\|_F \leq L_\sigma \|D_\ell A_{\ell-1}\|_F.$$

因此, 本文将 $D_\ell A_{\ell-1}$ 视为最基本的 activation perturbation object。

对矩阵 M , 记

$$\|M\|_{\text{op}} = \sigma_1(M), \quad \|M\|_F = \left(\sum_i \sigma_i(M)^2 \right)^{1/2}, \quad \|M\|_* = \sum_i \sigma_i(M).$$

稳定秩定义为

$$\text{srank}(M) = \frac{\|M\|_F^2}{\|M\|_{\text{op}}^2},$$

梯度核秩定义为

$$\text{nrnk}(G) = \frac{\|G\|_*^2}{\|G\|_F^2}.$$

4 局部一阶谱几何

本节说明为何 polar/SpecGrad 更新自然对应 operator-norm 几何, 而非 Frobenius 几何。

4.1 SpecGrad 家族

设

$$G = U \Sigma V^\top$$

为某个矩阵梯度。定义谱梯度更新族:

$$D_f(G) = U f(\Sigma) V^\top.$$

特殊情形包括:

$$f(\sigma) = \sigma \quad \Rightarrow \quad D_f(G) = G,$$

$$D_F(G) = G / \|G\|_F,$$

以及 polar 方向

$$f(\sigma) = 1_{\sigma>0}, \quad D_{\text{polar}}(G) = UV^\top.$$

4.2 Frobenius 与 operator-norm 约束下的一阶最优性

在当前参数点，对单个矩阵块考虑局部展开：

$$\mathcal{L}(W - D) - \mathcal{L}(W) = -\langle G, D \rangle + O(\|D\|^2).$$

因此，一阶目标是最大化

$$\langle G, D \rangle.$$

命题 4.1 (谱分配边界). 设 $G = U \text{diag}(\sigma) V^\top$ 。

(i) 在 Frobenius 球 $\|D\|_F \leq r$ 上，唯一最优方向为

$$D_F^* = rG/\|G\|_F,$$

最优一阶下降为

$$r\|G\|_F.$$

(ii) 在 operator-norm 球 $\|D\|_{\text{op}} \leq \eta$ 上，一个最优方向为

$$D_{\text{op}}^* = \eta UV^\top,$$

最优一阶下降为

$$\eta\|G\|_*.$$

证明. Frobenius 情况由 Cauchy-Schwarz 给出：

$$\langle G, D \rangle \leq \|G\|_F \|D\|_F \leq r\|G\|_F,$$

等号在 $D = rG/\|G\|_F$ 处取得。

Operator-norm 情况由 von Neumann trace inequality 给出：

$$\langle G, D \rangle \leq \sum_i \sigma_i(G) \sigma_i(D) \leq \eta \sum_i \sigma_i(G) = \eta\|G\|_*.$$

取 $D = \eta UV^\top$ 达到等号。 □

该命题解释了一个关键事实：

polar/flat spectrum 不是普适最优，而是 operator-norm 预算下的一阶最优。

如果公平比较的更新预算是 Frobenius 范数，那么梯度形状 $G/\|G\|_F$ 才是一阶最优；如果公平比较的是 operator norm，那么 polar 更新才是一阶最优。

5 激活扰动几何

本节把上一节的一阶更新几何转换为 activation perturbation 的语言。

考虑单层线性映射

$$Z = WA,$$

其中 A 是输入激活矩阵。更新 $W^+ = W - \eta D$ 后，直接 pre-activation 扰动为

$$\Delta Z = -\eta DA.$$

5.1 Polar 更新的 operator-norm 控制

若

$$D = D_{\text{polar}} = UV^\top,$$

则

$$\|D\|_{\text{op}} = 1.$$

因此对任意单样本 activation vector a , 有

$$\|Da\|_2 \leq \|a\|_2.$$

若步长为 η , 则

$$\|\Delta z(x)\|_2 \leq \eta \|h_{\ell-1}(x)\|_2.$$

这说明 polar/SpecGrad 更新给出了 per-sample worst-case activation perturbation bound。

对整个 batch, 有

$$\|DA\|_F \leq \|D\|_{\text{op}} \|A\|_F = \|A\|_F.$$

相反, Frobenius-normalized gradient direction

$$D_F = G/\|G\|_F$$

满足

$$\|D_F A\|_F \leq \|D_F\|_F \|A\|_{\text{op}} = \|A\|_{\text{op}}.$$

由于

$$\|A\|_F = \sqrt{\text{srnk}(A)} \|A\|_{\text{op}},$$

高稳定秩 activation 下, polar 更新可能导致更大的 batch-level activation movement。

因此, 本文区分两种稳定性:

operator/per-sample activation stability

与

batch-Frobenius activation stability.

SpecGrad 更自然地控制前者, 而非后者。

5.2 层级谱更新优势条件

设 loss 对 $Z = WA$ 是 β -smooth。则

$$\mathcal{L}(W - \eta D) \leq \mathcal{L}(W) - \eta \langle G, D \rangle + \frac{\beta \eta^2}{2} \|DA\|_F^2.$$

对 Frobenius-normalized direction $D_F = G/\|G\|_F$, 有

$$\langle G, D_F \rangle = \|G\|_F, \quad \|D_F A\|_F \leq \|A\|_{\text{op}}.$$

因此最优步长下的保证下降为

$$\text{Dec}_F \gtrsim \frac{\|G\|_F^2}{2\beta\|A\|_{\text{op}}^2}.$$

对 polar direction $D_S = UV^\top$, 有

$$\langle G, D_S \rangle = \|G\|_*, \quad \|D_S A\|_F \leq \|A\|_F.$$

因此

$$\text{Dec}_S \gtrsim \frac{\|G\|_*^2}{2\beta\|A\|_F^2}.$$

于是 spectral update 更优的充分条件为

$$\frac{\|G\|_*^2}{\|G\|_F^2} > \frac{\|A\|_F^2}{\|A\|_{\text{op}}^2},$$

也就是

$$\boxed{\text{nrnk}(G) > \text{srnk}(A).}$$

6 下游敏感度与 Sandwiched Stable Rank

单层条件只考虑 DA 对该层输出的扰动。但在深层网络中, 该扰动还要经过后续层传播。在线性化下, 可写成

$$\Delta F \approx BDA,$$

其中 B 是从该层输出到最终模型输出的 downstream Jacobian。

6.1 精确敏感度公式

定义

$$K_F^2 = \sup_{\|D\|_F \leq 1} \|BDA\|_F^2,$$

以及

$$K_S^2 = \sup_{\|D\|_{\text{op}} \leq 1} \|BDA\|_F^2.$$

定理 6.1 (Sandwiched block 的精确敏感度). 对映射 $J(D) = BDA$, 有

$$K_F^2 = \|B\|_{\text{op}}^2 \|A\|_{\text{op}}^2,$$

且

$$K_S^2 = \sum_i \sigma_i(B)^2 \sigma_i(A)^2,$$

其中奇异值按降序排列, 维度不足处以 0 补齐。

证明. Frobenius 情况使用 vectorization:

$$\text{vec}(BDA) = (A^\top \otimes B) \text{vec}(D).$$

因此

$$K_F = \|A^\top \otimes B\|_{\text{op}} = \|A\|_{\text{op}} \|B\|_{\text{op}}.$$

Operator-norm 情况令

$$B = U_B \Sigma_B V_B^\top, \quad A = U_A \Sigma_A V_A^\top.$$

写

$$Z = V_B^\top D U_A,$$

则 $\|Z\|_{\text{op}} \leq \|D\|_{\text{op}}$, 且

$$\|BDA\|_F^2 = \|\Sigma_B Z \Sigma_A\|_F^2.$$

根据 von Neumann rearrangement inequality,

$$\sup_{\|Z\|_{\text{op}} \leq 1} \|\Sigma_B Z \Sigma_A\|_F^2 = \sum_i \sigma_i(B)^2 \sigma_i(A)^2.$$

取使奇异向量对齐的 partial isometry 可达等号。 □

6.2 Sandwiched stable rank

定义

$$\text{ssrank}(B, A) = \frac{\sum_i \sigma_i(B)^2 \sigma_i(A)^2}{\sigma_1(B)^2 \sigma_1(A)^2}.$$

则

$$\frac{K_S^2}{K_F^2} = \text{ssrank}(B, A).$$

并且

$$1 \leq \text{ssrank}(B, A) \leq \min\{\text{srnk}(B), \text{srnk}(A)\}.$$

特别地, 当 $B = I$ 时,

$$\text{ssrank}(I, A) = \text{srnk}(A).$$

因此逐层 activation stable rank 是 downstream-aware sensitivity ratio 的特殊情形。

对应的下游修正谱更新条件为

$$\text{nrnk}(G) > \text{ssrank}(B, A).$$

该条件比 $\text{nrnk}(G) > \text{srnk}(A)$ 更精细, 因为它保留了下游 Jacobian 的奇异值谱。

7 已有 E11 实验证据

本节整理当前已有实验结果。它们支持本文的局部谱几何机制, 并包含 direct activation perturbation 的初步证据; downstream Jacobian 理论仍未被直接验证。

表 1: E11 已有局部几何证据摘要。比值均为 Muon-like/Adam 或 flat-polar/GD-spectrum。

证据项	指标	数值	解释
更新谱塑形	nrUpdate	2.017 [1.905, 2.136]	Muon-like 更新核秩更高
更新谱塑形	stUpdate	4.765 [4.582, 4.955]	Muon-like 更新稳定秩更高
一阶校准	$\rho(\Delta L, \langle G, D \rangle)$	0.9803 [0.9787, 0.9817]	one-step loss 由一阶内积很好解释
Frobenius 预算	flat/GD	0.6071 [0.5846, 0.6304]	flat/polar 谱分配输给梯度谱分配
Operator 预算	flat/GD	1.689 [1.614, 1.768]	flat/polar 谱分配胜出

7.1 更新谱塑形

E11 结果显示, Muon-like 极分解更新稳定地产生更平、更高秩的 update spectrum。在 noisy mini-batch default setting 的 equal-update control 下, nrUpdate 比值约为 2.017, stUpdate 比值约为 4.765。这说明极分解更新确实改变更新矩阵奇异值分布, 但这只是机制事实, 不是性能声明。

7.2 一阶损失下降校准

E11 记录的 `update_grad_inner` 对应本文记号中的

$$\langle G, D \rangle,$$

即正的一阶下降 proxy。已有结果显示, one-step 实际损失下降与该 proxy 的 Spearman 相关约为 0.9803, 说明在当前短步长范围内, 使用局部一阶模型是合理的。

7.3 范数几何边界

谱分配 probe 固定梯度奇异向量, 只改变奇异值分配, 并分别在 Frobenius 预算与 operator-norm 预算下比较 flat/polar 与 GD-spectrum。结果表明:

$$\text{Frobenius budget: } \text{flat/GD} = 0.6071 < 1,$$

但

$$\text{operator budget: } \text{flat/GD} = 1.689 > 1.$$

这与附录 A 中的一阶最优性推导完全一致。

7.4 神经网络负控

神经网络 sanity checks 显示, 高 update rank 并不自动带来更好一阶进展。Deep MNIST MLP、MNIST Patch surrogate 与 MNIST ConvNet 都保留 Muon-like 更新的高核秩/高稳定秩 signature, 但 one-step 对齐比仍显著低于 Adam。见表 2。

这部分证据支持本文的谨慎表述:

SpecGrad 改变更新谱几何, 但谱扩散是否有利取决于 activation/downstream geometry。

表 2: 神经网络 sanity checks: 高秩更新不自动意味着更好一阶进展。

任务	nrUpdate	stUpdate	one-step 对齐比
Deep MNIST MLP	2.262 [2.175, 2.353]	18.31 [16.26, 20.62]	0.5978 [0.5633, 0.6345]
MNIST Patch + 共享权重	4.235 [3.834, 4.677]	12.89 [11.77, 14.12]	0.5222 [0.4943, 0.5516]
MNIST ConvNet	3.718 [3.451, 4.006]	12.03 [11.03, 13.12]	0.677 [0.6321, 0.7251]

7.5 预测边界尚未完成

当前边界预测器只能作为描述性分析。已有 audit 显示 in-sample fit 具有探索价值，但 held-out generalization 还不够稳定；部分 held-out setting 还存在 positive/negative label 退化问题。因此，当前不应声称已有一个可迁移的强预测规则。

8 实验计划与待完成实验

本节区分已完成实验与待完成实验。当前完成的 E11 局部几何实验见第 7 节。Activation perturbation diagnostics 已完成一个初步版本；downstream Jacobian、长尾小 batch 与现代架构实验仍是待完成实验。

8.1 实验一：Activation perturbation diagnostics

状态。 已完成初步版本。

目标。 直接测量 SpecGrad / polar update 是否在 activation perturbation 上表现出 operator-norm 意义下的稳定性。

对每层记录

$$\Delta Z_{\ell, \text{direct}} = (W_{\ell}^{t+1} - W_{\ell}^t) A_{\ell-1}^t.$$

测量：

$$\frac{\|\Delta Z_{\ell, \text{direct}}\|_F}{\|Z_{\ell}^t\|_F}, \quad \frac{\|\Delta Z_{\ell, \text{direct}}\|_{\text{op}}}{\|Z_{\ell}^t\|_{\text{op}}},$$

以及 per-sample 最大扰动：

$$\max_b \frac{\|(W_{\ell}^{t+1} - W_{\ell}^t) h_{\ell-1}(x_b)\|_2}{\|h_{\ell-1}(x_b)\|_2}.$$

预期。 SpecGrad 应更自然地控制 operator/per-sample 指标，而不一定降低 batch-Frobenius movement。

结果。 在 matched global update size 的 equal-update control 中，Muon 在当前 activation-defined tasks 上降低了 operator-norm 与 worst-case per-sample pre-activation perturbation，但没有统一降低 batch-Frobenius movement。具体地，Muon/Adam 的相对 operator perturbation ratio 为 0.8390 [0.8310, 0.8471]，max per-sample perturbation ratio 为 0.7279 [0.7198, 0.7361]。

表 3: Equal-update activation perturbation diagnostics. Ratios are Muon/Adam geomeans with 95% confidence intervals. Matrix Sensing is excluded because its diagnostic A is a measurement-operator proxy, not a layer activation matrix.

Metric	Task group	Muon/Adam ratio	Interpretation
Relative $\ D_i A_i\ _F$	All activation-defined tasks	1.142[1.13, 1.153]	Muon higher
Relative $\ D_i A_i\ _F$	MF-with-input	1.163[1.152, 1.175]	Muon higher
Relative $\ D_i A_i\ _F$	Small MLP digits	0.714[0.6767, 0.7532]	Muon lower
Relative $\ D_i A_i\ _{op}$	All activation-defined tasks	0.839[0.831, 0.8471]	Muon lower
Relative $\ D_i A_i\ _{op}$	MF-with-input	0.8433[0.8353, 0.8514]	Muon lower
Relative $\ D_i A_i\ _{op}$	Small MLP digits	0.7382[0.6923, 0.7872]	Muon lower
Max per-sample $\ D_i a_b\ /\ a_b\ $	All activation-defined tasks	0.7279[0.7198, 0.7361]	Muon lower
Max per-sample $\ D_i a_b\ /\ a_b\ $	MF-with-input	0.7439[0.7357, 0.7522]	Muon lower
Max per-sample $\ D_i a_b\ /\ a_b\ $	Small MLP digits	0.4226[0.3979, 0.4488]	Muon lower
Mean per-sample $\ D_i a_b\ /\ a_b\ $	All activation-defined tasks	1.206[1.19, 1.222]	Muon higher
Mean per-sample $\ D_i a_b\ /\ a_b\ $	MF-with-input	1.248[1.232, 1.264]	Muon higher
Mean per-sample $\ D_i a_b\ /\ a_b\ $	Small MLP digits	0.5134[0.4826, 0.5461]	Muon lower

但相对 Frobenius perturbation ratio 为 1.142 [1.130, 1.153], mean per-sample perturbation ratio 为 1.206 [1.190, 1.222]。见表 3。

这个结果支持本文的范数几何区分: Muon-like polar 更新可以降低 operator/per-sample worst-case activation perturbation, 同时 batch-level Frobenius movement 仍然依赖任务族。它不支持“Muon 一般更稳定”的表述。Matrix Sensing 没有被纳入该诊断, 因为其 A 是 measurement-operator proxy, 而不是层激活矩阵。

8.2 实验二: Activation stable rank 与层级条件

状态. **TBD**。

计算

$$\text{srnk}(A_{\ell-1}) = \frac{\|A_{\ell-1}\|_F^2}{\|A_{\ell-1}\|_{op}^2}, \quad \text{nrnk}(G_\ell) = \frac{\|G_\ell\|_*^2}{\|G_\ell\|_F^2}.$$

检验条件

$$\text{nrnk}(G_\ell) > \text{srnk}(A_{\ell-1})$$

是否预测该层 polar/SpecGrad 的一阶优势。

结果. **TBD**。

8.3 实验三: Downstream-aware activation perturbation

状态. **TBD**。

目标是测量

$$\|B_\ell D_\ell A_{\ell-1}\|_F$$

或使用 JVP 估计

$$\|J_\theta D_\ell\|_F.$$

比较

$$D_{\text{spec}} = \text{polar}(G_\ell)$$

与

$$D_{\text{gd}} = G_\ell / \|G_\ell\|_F.$$

核心指标为

$$\frac{\langle G_\ell, D_{\text{spec}} \rangle^2 / \|J_\theta D_{\text{spec}}\|_F^2}{\langle G_\ell, D_{\text{gd}} \rangle^2 / \|J_\theta D_{\text{gd}}\|_F^2}.$$

结果. **TBD**。

8.4 实验四：长尾小 batch 激活实验

状态. **TBD**。

构造长尾分类或 synthetic long-tail mode 数据。检验 rare direction 可见性条件

$$\frac{Bp_c}{1-\beta} \gtrsim 1.$$

记录 tail-class loss、tail activation drift、tail activation coverage、minibatch spectral-tail consistency 与 effective nuclear rank。

结果. **TBD**。

8.5 实验五：现代架构激活扰动 benchmark

状态. **TBD**。

在 Transformer、现代 MLP 或 CNN 架构中测量

$$\|\Delta A_\ell\|_F, \quad \|\Delta A_\ell\|_{\text{op}}, \quad \text{srnk}(A_\ell), \quad \|J_\theta D_\ell\|_F.$$

本实验不以 attention 为核心，而是直接观察 activation perturbation。

结果. **TBD**。

9 讨论

本文主张将谱梯度更新理解为 activation perturbation geometry，而不是简单理解为“更高 rank 的更新”。这一表述有三个好处。

第一，它解释了为什么 polar/SpecGrad 更新在 operator-norm 预算下自然。由于

$$\|UV^\top\|_{\text{op}} = 1,$$

它给出了清晰的 per-sample activation perturbation 控制：

$$\|UV^\top a\|_2 \leq \|a\|_2.$$

第二，它解释了为什么高秩更新可能失败。Batch-level 扰动由

$$\|DA\|_F$$

决定，而 polar 更新的上界是 $\|A\|_F$ ，可能随着 activation stable rank 增大而增大。因此，高秩谱扩散只有在这些方向带来足够一阶收益、并且 downstream sensitivity 不高时才有利。

第三，它自然引入 downstream-aware stable rank。若扰动通过后续网络传播为

$$BDA,$$

则相关几何量应为

$$\text{ssrank}(B, A),$$

而非仅 $\text{srnk}(A)$ 。这说明 layerwise activation stable rank 可能是保守上界。

已有 E11 实验与这一观点一致：Muon-like 更新稳定地产生更平、更高秩的 update spectra，但进展优势是条件化的。当前证据不支持“Muon 一般更稳定”或“更高 rank 一般更好”的宽泛结论；更安全的说法是，Muon/SpecGrad 是 update-spectrum shaping 方法，其效应由任务、层、范数几何和下游敏感度共同决定。

10 结论

本文将谱梯度更新整理为一种激活扰动几何。核心结论如下：

- (1) Polar/SpecGrad 更新是 operator-norm 预算下的一阶最优方向，而不是 Frobenius 预算下的一阶最优方向。
- (2) 对层激活而言，关键对象是 DA 。SpecGrad 控制 operator/per-sample activation perturbation，但不保证 batch-Frobenius perturbation 更小。
- (3) 对深层网络而言，真正相关的是 BDA 。对应的敏感度比是
$$\text{ssrank}(B, A) = \frac{\sum_i \sigma_i(B)^2 \sigma_i(A)^2}{\sigma_1(B)^2 \sigma_1(A)^2}.$$
- (4) 已有 E11 实验支持局部谱几何机制：Muon-like 更新重塑 update spectrum；one-step 下降由 $\langle G, D \rangle$ 很好解释；polar 谱分配在 operator-norm 预算下有利，但在 Frobenius 预算下不利。
- (5) 尚需补充直接的 activation perturbation、downstream Jacobian 和长尾小 batch 实验。

因此，最稳妥的论文级表述是：

谱梯度更新的收益不是来自高秩本身，而来自高秩谱扩散与激活/下游几何之间的匹配。

A 核心证明细节

A.1 谱范数球与核范数对偶

设 $G = U\Sigma V^\top$ 。由 von Neumann trace inequality, 任意 D 满足

$$\langle G, D \rangle \leq \sum_i \sigma_i(G) \sigma_i(D).$$

若 $\|D\|_{\text{op}} \leq \eta$, 则 $\sigma_i(D) \leq \eta$, 所以

$$\langle G, D \rangle \leq \eta \sum_i \sigma_i(G) = \eta \|G\|_*$$

取 $D = \eta UV^\top$ 达等号。因此

$$\max_{\|D\|_{\text{op}} \leq \eta} \langle G, D \rangle = \eta \|G\|_*.$$

A.2 Frobenius 球与 Frobenius 范数对偶

由 Cauchy–Schwarz,

$$\langle G, D \rangle \leq \|G\|_F \|D\|_F.$$

若 $\|D\|_F \leq r$, 则

$$\langle G, D \rangle \leq r \|G\|_F.$$

取 $D = rG/\|G\|_F$ 达等号。

A.3 Sandwiched sensitivity 的 Frobenius 情况

对 $J(D) = BDA$, 有

$$\text{vec}(BDA) = (A^\top \otimes B) \text{vec}(D).$$

因此

$$\sup_{\|D\|_F \leq 1} \|BDA\|_F = \|A^\top \otimes B\|_{\text{op}}.$$

Kronecker product 的 operator norm 满足

$$\|A^\top \otimes B\|_{\text{op}} = \|A\|_{\text{op}} \|B\|_{\text{op}}.$$

所以

$$K_F^2 = \|B\|_{\text{op}}^2 \|A\|_{\text{op}}^2.$$

A.4 Sandwiched sensitivity 的 operator-norm 情况

令

$$B = U_B \Sigma_B V_B^\top, \quad A = U_A \Sigma_A V_A^\top.$$

则

$$\|BDA\|_F = \|\Sigma_B Z \Sigma_A\|_F, \quad Z = V_B^\top D U_A.$$

若 $\|D\|_{\text{op}} \leq 1$, 则 $\|Z\|_{\text{op}} \leq 1$ 。因此

$$\sup_{\|D\|_{\text{op}} \leq 1} \|BDA\|_F^2 = \sup_{\|Z\|_{\text{op}} \leq 1} \|\Sigma_B Z \Sigma_A\|_F^2.$$

展开为

$$\|\Sigma_B Z \Sigma_A\|_F^2 = \text{tr}(\Sigma_B^2 Z \Sigma_A^2 Z^\top).$$

由重排不等式, 最大值为

$$\sum_i \sigma_i(B)^2 \sigma_i(A)^2.$$

取使 A 与 B 的奇异方向对齐的 partial isometry 可达等号。

B 建议实验指标与记录协议

后续实验建议记录以下量。

B.1 更新谱指标

$$\text{nrank}(D) = \frac{\|D\|_*^2}{\|D\|_F^2}, \quad \text{srnk}(D) = \frac{\|D\|_F^2}{\|D\|_{\text{op}}^2}.$$

B.2 激活扰动指标

$$\Delta Z_{\ell, \text{direct}} = (W_\ell^{t+1} - W_\ell^t) A_{\ell-1}^t.$$

记录

$$\|\Delta Z_{\ell, \text{direct}}\|_F, \quad \|\Delta Z_{\ell, \text{direct}}\|_{\text{op}},$$

以及归一化版本。

B.3 一阶进展指标

$$\langle G_\ell, D_\ell \rangle, \quad \sum_\ell \langle G_\ell, D_\ell \rangle.$$

B.4 下游扰动指标

用 JVP 估计

$$\|J_\theta D\|_F^2.$$

比较

$$\frac{\langle G, D \rangle^2}{\|J_\theta D\|_F^2}$$

在不同更新方向上的差异。

C 安全表述与需避免表述

C.1 可以安全使用的表述

- SpecGrad / Muon-like 更新是 update-spectrum shaping 方法。
- Polar 更新是一阶线性化目标在 operator-norm 预算下的最优方向。
- 谱更新是否有利取决于任务、层、激活稳定秩、下游 Jacobian 敏感度和更新预算几何。
- 高 update rank 是机制事实，不是性能保证。

C.2 应避免的表述

- Muon 一般比 Adam 更好。
- 更高 rank/stable rank 更新一般带来更低损失。
- 当前 E11 边界预测器已经能稳定预测 unseen tasks。
- 当前实验已经证明 SpecGrad 改善 activation stability 或 long-tail generalization。

参考文献

- [1] Damek Davis and Dmitriy Drusvyatskiy. *When Do Spectral Gradient Updates Help in Deep Learning?* arXiv:2512.04299, 2026.
- [2] Lizhang Chen, Jonathan Li, and Qiang Liu. *Muon Optimizes Under Spectral Norm Constraints.* arXiv:2506.15054, 2025.
- [3] Amartya Sanyal, Philip H. S. Torr, and Puneet K. Dokania. *Stable Rank Normalization for Improved Generalization in Neural Networks and GANs.* arXiv:1906.04659, 2020.
- [4] Tianyang Liu. *E11 Condition Geometry Experiments for Muon Update-Spectrum Shaping.* GitHub branch `codex/e11-three-problem-condition-geometry`, 2026.